

5 Adaptive Filter

Dozent R. Vetter

Ziel

- Einführung in die Algorithmen der adaptiven Filter anhand eines Filters finiter Impulsantwort.

Kontext

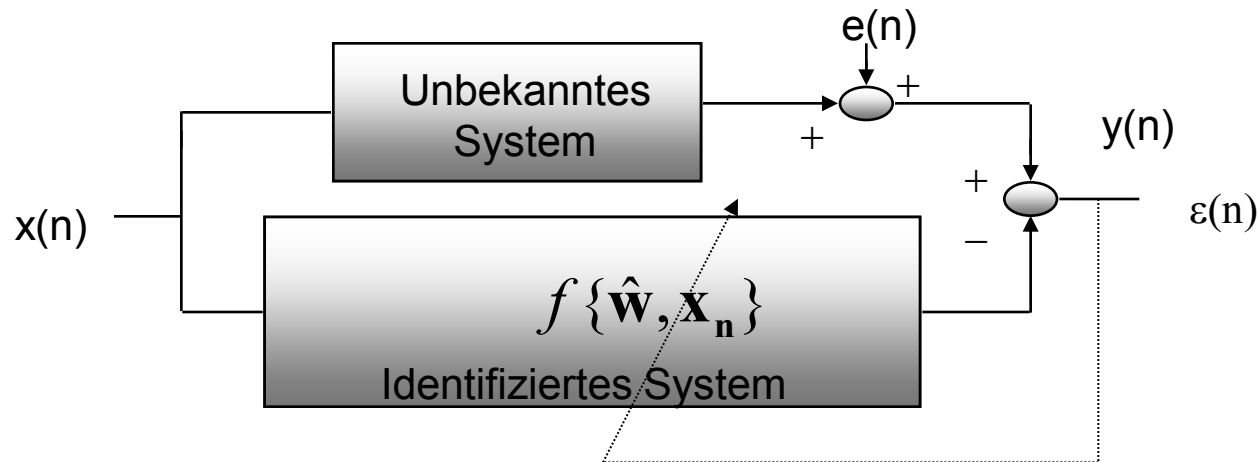
- Motivation
 - Viele praktisch vorkommende Signale sind **nicht-stationär**, während die bis jetzt präsentierten Methoden der DigSV für stationäre Signale geeignet sind.
 - Eine einfache Methode besteht darin, das Signal segmentweise zu bearbeiten; es wird eine Segmentlänge gewählt, auf der das Signal als stationär betrachtet werden kann (z.B. Sprache).
- Lösung
 - Eine attraktive Lösung stellen adaptive Methoden des DigSV dar.
 - Die Parameterschätzungsalgorithmen werden sehr einfach, brauchen wenig Speicherplatz und Rechenzeit, und können sich an sich ändernde Umfelder anpassen.

Prinzip (1/3)

- Bei jedem neuen Sample werden die geschätzten Parameter wie folgt aktualisiert :

Neue Parameter = Alte Parameter + Aktualisierung (Fehler)

Illustration des adaptiven Identifikationsprozesses



Aktualisierung bei jedem neuen Sample

Prinzip (2/3)

- Die Parameteraktualisierung schreibt sich

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mathbf{k}_n \{\varepsilon(n)\}$$

- Die verschiedenen adaptiven Algorithmen unterscheiden sich prinzipiell durch eine spezifische Wahl der Aktualisierungsfunktion $\mathbf{k}_n\{.\}$.
- Die Konvergenz- und Stabilitätseigenschaften des Parameteraktualisierungsalgorithmus hängen von $\mathbf{k}_n\{.\}$ ab.

Prinzip (3/3)

- Wir illustrieren diese adaptive Methode anhand eines MA-Systems (kann problemlos auch für AR und ARMA Systeme angewendet werden). Das Ausgangssignal und der Fehler sind

$$\hat{y}(n) = \sum_{i=0}^p w(i)x(n-i)$$

$$\begin{aligned}\varepsilon(n) &= y(n) - \hat{y}(n) = y(n) - \sum_{i=0}^p w(i)x(n-i) \\ &= y(n) - \mathbf{w}^T \mathbf{x}_n \quad \text{avec} \quad \begin{cases} \mathbf{w}^T = [b(0), \dots, b(p)] \\ \mathbf{x}_n^T = [x(n), \dots, x(n-p)] \end{cases}\end{aligned}$$

LMS oder stochastischer Gradient (1/2)

- Beim LMS (engl. Least Mean Square) besteht die Aktualisierungsfunktion aus dem Gradienten (partielle Ableitung in Bezug auf die Parameter) des quadratischen Fehlers :

$$\begin{aligned}\mathbf{w}_{n+1} &= \mathbf{w}_n + \mu \left\{ -\frac{\partial(\varepsilon(n)^2)}{\partial \mathbf{w}_n} \right\} \\ &= \mathbf{w}_n + \mu \{ \mathbf{x}_n \varepsilon(n) \}\end{aligned}$$

$$\text{wo } \mathbf{x}_n^T = [x(n), \dots, x(n-p)]$$

$$\varepsilon(n) = y(n) - \mathbf{w}_n^T \mathbf{x}_n^T$$

μ : Faktor zur Einstellung der
Geschwindigkeit und Stabilität der Adaption

LMS oder stochastischer Gradient (2/2)

- Vorteile
 - Einfach abzuleiten und schnell zu programmieren
 - Braucht wenig Rechenleitung
- Nachteile
 - Parameterkonvergenz langsam
 - Wird schneller wenn μ grösser
 - Remanenter Fehler
 - Wird grösser mit μ
 - Stabilität
 - Unstabil wenn μ zu gross $0 < \mu < 2/((p+1) \cdot \sigma_x^2)$
- Weitere verbesserte adaptive Algorithmen
 - LMS-normiert, RLS
- Literatur
 - S. Haykin, «Adaptive Filters», Prentice Hall

Bibliographie

- S.V. Vaseghi, «Advanced Digital Signal Processing and Noise Reduction», WILEY.
- K.D. Kammeyer, «Digitale Signalverarbeitung», Springer Vieweg, S 209.
- B.U. Köhler, «Konzepte der statistischen Signalverarbeitung», Springer, S 157.
- S. Haykin, «Adaptive Filter Theory», Prentice Hall, S 338